


Curso Insper - Regressão e Classificação.

Considere o seguinte conjunto de dados


$$x_0, \dots, x_{N-1}$$

$$y_0, \dots, y_{N-1}$$

O gráfico de dispersão dos dados tem o seguinte formato:




Queremos saber se os valores de x predizem de "alguma forma" os valores de y .



Suponhamos que x e y apresentem a seguinte relação:

$$y = a \cdot x + b$$

Como não é possível encontrar os parâmetros a e b de modo que o comportamento seja reproduzido com exatidão, definiremos um critério razoável:



$\{ \}$: parentese de nível
(notação própria)

a e b são escolhidos tal que:

$$\hat{a}, \hat{b} = \arg \min_{a, b} \sum_{i=0}^{N-1} (y_i - \hat{y}(x_i))^2$$

Onde:

\hat{a}, \hat{b} são os parâmetros que procuramos

$$\hat{y}(x_i) = \hat{a} \cdot x_i + \hat{b}$$

$\arg \min ()$ = argumentos que minimizam a função à direita.

Assim, analisemos a função do nosso critério:

$$\begin{aligned} & \sum_{n=0}^{N-1} (y_i - \hat{y}(x_i))^2 \\ &= \sum_{n=0}^{N-1} (y_i - (a \cdot x_i + b))^2 \\ &= \sum_{n=0}^{N-1} (y_i^2 - 2 \cdot y_i \cdot (a \cdot x_i + b) + (a \cdot x_i + b)^2) \\ &= \sum_{n=0}^{N-1} (y_i^2 - \underline{2 y_i a x_i} - \underline{2 y_i b} \\ & \quad + \underline{a^2 x_i^2} + \underline{2 a x_i b} + b^2) \\ &= \sum_{n=0}^{N-1} (a^2 x_i^2 + a \cdot (2 x_i b - 2 y_i x_i) \\ & \quad + y_i^2 - 2 y_i b + b^2) \\ &= a^2 \sum_{n=0}^{N-1} x_i^2 + a \cdot \sum_{n=0}^{N-1} (2 x_i b - 2 y_i x_i) + \sum_{n=0}^{N-1} (y_i^2 - 2 y_i b + b^2) \end{aligned}$$



Portanto, p/ b fixado, temos uma função de grau 2 de a .

Da mesma forma:

$$\begin{aligned} &= \sum_{n=0}^{N-1} (y_i^2 - \underline{2 y_i a x_i} - \underline{2 y_i b} \\ & \quad + \underline{a^2 x_i^2} + \underline{2 a x_i b} + b^2) \\ &= \sum_{n=0}^{N-1} (b^2 + b \cdot (2 a x_i - 2 y_i) + y_i^2 - 2 y_i a x_i + a^2 x_i^2) \\ &= b^2 \sum_{n=0}^{N-1} 1 + b \sum_{n=0}^{N-1} 2 a x_i - 2 y_i + \sum_{n=0}^{N-1} y_i^2 - 2 y_i a x_i + a^2 x_i^2 \end{aligned}$$

Portanto, p/ um a fixo, também temos uma função de grau 2 de b .

função de grau 2, onde o termo de maior grau tem coeficiente positivo tem um ponto de derivada zero que corresponde ao mínimo da função:



nível 1 \rightarrow menores valores
nível 3 \rightarrow maiores valores.

Chamemos nossa função critério de S , então:

$$\frac{\partial S}{\partial a} \cdot \hat{a} + \frac{\partial S}{\partial b} \cdot \hat{b} = 0 \Rightarrow \nabla S = 0$$

Ou seja, procuramos o ponto onde o gradiente é igual a zero.

Relembramos a função S

$$S = \sum_{i=0}^{N-1} \{ a^2 \cdot x_i^2 + a \cdot (2x_i b - 2y_i x_i) + y_i^2 - 2y_i b + b^2 \}$$

$$\frac{\partial S}{\partial a} = 2a \underbrace{\sum_{i=0}^{N-1} x_i^2}_{\gamma} + 2b \underbrace{\sum_{i=0}^{N-1} x_i}_{\delta} - 2 \underbrace{\sum_{i=0}^{N-1} y_i x_i}_{\eta}$$

$$\frac{\partial S}{\partial b} = 2a \underbrace{\sum_{i=0}^{N-1} x_i}_{\gamma} - 2 \underbrace{\sum_{i=0}^{N-1} y_i}_{\varphi} + 2Nb$$

Simplificando, acabamos com o sistema:

$$\begin{cases} a \cdot \gamma + b \delta = \eta \\ a \gamma + Nb = \varphi \end{cases}$$

Agora basta resolvermos o sistema de equações.

Regressão logística

Diferente do caso anterior, queremos prever uma variável categórica.

Por exemplo...

Dado um valor x , qual a classe y ?

$$y = \{0, 1\}$$

$$x = \mathbb{R}$$

Neste caso, podemos utilizar a função logística:

$$P(Y=1) = g(x) = \frac{1}{1 + e^{-(ax+b)}}$$

Perceba que:

$$\lim_{x \rightarrow \infty} g(x) = 1$$

$$\lim_{x \rightarrow \infty} g(x) = 0 \quad \text{se } a > 0$$

$$\lim_{x \rightarrow \infty} g(x) =$$

$$\lim_{x \rightarrow -\infty} g(x) = 1 \quad \text{se } a < 0$$

Agora, note que:

$$\frac{P(Y=1)}{P(Y=0)} = \frac{P(Y=1)}{1 - P(Y=1)} = \frac{\frac{1}{1 + e^{-(ax+b)}}}{1 - \frac{1}{1 + e^{-(ax+b)}}} \Bigg\} A_1$$

$$= \frac{A_1}{\frac{1 + e^{-(ax+b)} - 1}{1 + e^{-(ax+b)}}}$$

$$= \frac{1}{1 + e^{-(ax+b)}} \cdot \frac{1 + e^{-(ax+b)}}{e^{-(ax+b)}}$$

Portanto,

$$\frac{P(Y=1)}{P(Y=0)} = e^{ax+b}$$

Aplicando o logaritmo neperiano:

$$\log_e \left(\frac{\mathbb{P}(Y=1)}{\mathbb{P}(Y=0)} \right) = \log_e (e^{ax+b})$$
$$= (ax+b) \cdot \log_e(e) \quad \uparrow$$

Assim voltamos p/ o problema da regressão.

Após descobrir \hat{a} e \hat{b} , digamos que p/ um determinado x_i temos que $\hat{a}x_i + \hat{b} = k$.

$$\log_e \left(\frac{\mathbb{P}(Y=1)}{1 - \mathbb{P}(Y=1)} \right) = k$$

$$\frac{\mathbb{P}(Y=1)}{1 - \mathbb{P}(Y=1)} = e^k$$

$$\mathbb{P}(Y=1) = e^k \cdot (1 - \mathbb{P}(Y=1))$$

$$\mathbb{P}(Y=1) = e^k - e^k \cdot \mathbb{P}(Y=1)$$

$$\mathbb{P}(Y=1) + e^k \cdot \mathbb{P}(Y=1) = e^k$$


$$\mathbb{P}(Y=1) \cdot (1 + e^k) = e^k$$

$$\mathbb{P}(Y=1) = \frac{e^k}{1 + e^k}$$

Cursos ROC:

ROC: Receiver operating characteristics.

É uma maneira de avaliar classificadores. Constrói-se um gráfico:



classificadores ruins.

$$TFP = \frac{FP}{N}$$

$$TPV = \frac{VP}{P}$$

TFP = Taxa de falsos positivos

TPV = Taxa de verdadeiros positivos.